

企业知识库建设白皮书

一、什么是 RAG

RAG (Retrieval-Augmented Generation, 检索增强生成) 是一种结合信息检索与大语言模型生成能力的技术框架。它的核心思路是：先从外部知识库中检索出与用户问题最相关的文档片段，再把这些片段作为上下文喂给大语言模型，让模型基于真实资料生成答案，从而有效缓解大模型的幻觉问题。

二、为什么要用向量检索

传统的关键词检索只能匹配字面相同的词语，无法理解语义。例如用户问“公司多久发一次工资”，文档里写的是“薪酬按月结算”，关键词检索可能匹配不到，而向量检索通过语义相似度能够命中。向量检索的核心是把文本转换成高维向量，再计算向量之间的距离来判断相似程度。

三、部门编制表（示例表格）

部门	人数	负责人	主要职责
研发部	18	张三	产品研发与迭代
产品部	8	李四	需求分析与设计
测试部	10	王五	质量保障与验收
运维部	6	赵六	系统部署与监控

四、实施路线图

第一阶段：完成文档解析与向量化，搭建基础的检索问答链路。第二阶段：引入重排序与混合检索，提升检索准确率。第三阶段：接入 Agent 能力，支持复杂问题的自动拆解与多跳查询。

本项目的目标是构建一个企业私有知识库智能问答助手，支持 PDF、Markdown、TXT 三种格式文档的上传，实现多轮对话与来源引用，并能在本地低成本运行。